

Calidad y Preprocesamiento de Datos

MCIC VÍCTOR MANUEL CORZA VARGAS
MC FERNANDO AVITÚA VARELA

Introducción a la Calidad de datos

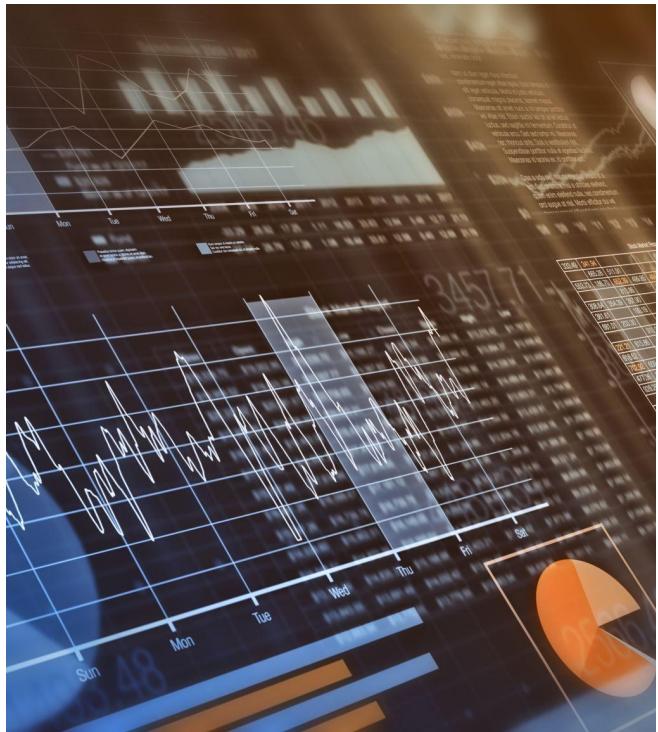


Introducción

Objetivos:

- Principales causas de problemas de calidad en bases de datos.
- Dimensiones de calidad de información y datos.
- Interdependencia de las dimensiones de calidad.

Causas de Problemas de Calidad en las Bases de Datos



Los problemas de calidad en bases de datos pueden originarse por diversas razones, entre ellas:

- ❑ **Errores Humanos:** Ingresos incorrectos, duplicados, omisiones.
- ❑ **Sistemas Heterogéneos:** Integración de datos de diferentes fuentes sin estandarización.
- ❑ **Problemas de Migración:** Conversión incorrecta de datos entre sistemas.

Causas de Problemas de Calidad en las Bases de Datos



- ❑ Datos Obsoletos: Falta de actualización de la información.
- ❑ Falta de Estándares: Ausencia de reglas claras para la gestión de datos.
- ❑ Errores de Captura Automática: Fallas en sensores, OCR, procesos ETL defectuosos.

Calidad de Información

Se refiere a la utilidad de los datos en un contexto específico. Los principales factores que influyen en la calidad de la información incluyen:

- Relevancia: La información obtenida a partir de los datos disponibles debe ser útil y aplicable a la situación.
- Oportunidad: La información debe estar disponible en el momento adecuado.
- Exactitud: La información debe representar la realidad con precisión.
- Interpretabilidad: La información debe ser comprensible y utilizable por los usuarios.



Calidad de Datos

En el ámbito de la calidad de datos y de la información se ha adoptado la palabra dimensión para identificar aquellos aspectos de los datos que pueden ser medidos y a través de los cuales su calidad puede ser cuantificada. Entre las principales dimensiones de calidad de datos encontramos:

Exactitud: Los datos reflejan la realidad sin errores.

Compleitud: No hay datos faltantes o vacíos.

Consistencia: Los datos mantienen coherencia a lo largo del sistema.

Validez: Cumplen con las *reglas* y formatos esperados.

Accesibilidad: Disponibilidad fácil para los usuarios autorizados.

Trazabilidad: Se puede rastrear el origen y transformaciones de los datos.

Interdependencia de Dimensiones de Calidad de Datos

Las dimensiones de calidad de datos no son independientes, sino que interactúan entre sí de diversas maneras:

Relación entre Exactitud y Consistencia: Datos exactos pero inconsistentes pueden generar confusión en los análisis.

Interdependencia de Dimensiones de Calidad de Datos

Relación entre Exactitud y Consistencia: Datos exactos pero inconsistentes pueden generar confusión en los análisis.

Puedes tener dos bases de datos con información real (exacta), pero si una usa "EE.UU." y la otra "Estados Unidos", tus reportes se duplicarán.

Interdependencia de Dimensiones de Calidad de Datos

Compleitud y Validez: Un dato puede estar presente (completo) pero no cumplir con los requisitos esperados (no válido).

Interdependencia de Dimensiones de Calidad de Datos

Compleitud y Validez: Un dato puede estar presente (completo) pero no cumplir con los requisitos esperados (no válido).

Este es el clásico caso de "rellenar por llenar". Un campo de "Teléfono" puede estar lleno (completo), pero si tiene el texto "12345", no es válido.

La completitud sin validez es solo ruido. Los datos inválidos son más peligrosos que los datos faltantes porque pueden sesgar los algoritmos sin que te des cuenta.

Interdependencia de Dimensiones de Calidad de Datos

Oportunidad vs. Exactitud: A veces, para que un dato sea 100% exacto, tardamos demasiado en procesarlo.

En el mundo real, a veces preferimos un dato 95% exacto *ahora*, que uno 100% exacto dentro de un mes.

Interdependencia de Dimensiones de Calidad de Datos

Accesibilidad y Seguridad: Si bien los datos deben ser accesibles, también deben cumplir con requisitos de seguridad para evitar el acceso no autorizado.

Este es el "Gran Dilema" del Gobierno de Datos.

Refinamiento: Más que una relación, es una tensión equilibrada. Demasiada seguridad mata la agilidad; demasiada accesibilidad compromete la privacidad. (Para equilibrar se usan frameworks como GDPR)

General Data Protection Regulation

Es la ley de **privacidad y seguridad** más estricta del mundo. Fue creada por la Unión Europea (entró en vigor en 2018), pero tiene un alcance **global**.

¿Por qué afecta a las empresas aunque no estén en Europa?

Aquí está el truco: si una empresa (aunque esté en México, Argentina o EE. UU.) ofrece productos o servicios a personas en la Unión Europea, o simplemente recolecta sus datos, **debe cumplir con el GDPR**. Por eso ves avisos de "Aceptar Cookies" en casi todas las webs del mundo.

Puntos clave del GDPR

El GDPR es relevante porque impone reglas sobre cómo se manejan las dimensiones de calidad de datos:

- **Consentimiento:** Los usuarios deben dar permiso explícito y claro para que se usen sus datos. No son válidas las casillas pre-marcadas.
- **Derecho al olvido:** Si un usuario lo pide, la empresa debe borrar todos sus datos personales.
- **Portabilidad:** El usuario tiene derecho a pedir que le entreguen sus datos en un formato fácil de leer para llevarlos a otro lado.
- **Multas masivas:** El incumplimiento puede costar hasta **20 millones de euros o el 4% de la facturación global** anual de la empresa (lo que sea más alto).

Puntos clave del GDPR

Gracias al GDPR, muchas empresas tuvieron que limpiar sus bases de datos, mejorando drásticamente su **Calidad de Datos**, ya que la ley exige que los datos sean "exactos y, si es necesario, actualizados".

2.3 Modelo de Medición de Calidad de Datos

Para medir la calidad de datos, se emplean métricas y técnicas específicas:

Métricas básicas: **Precisión** (% de valores correctos), **completitud** (% de datos sin valores nulos), **consistencia** (comparación entre fuentes), **oportunidad** (Tiempo necesario para que los datos estén disponibles)

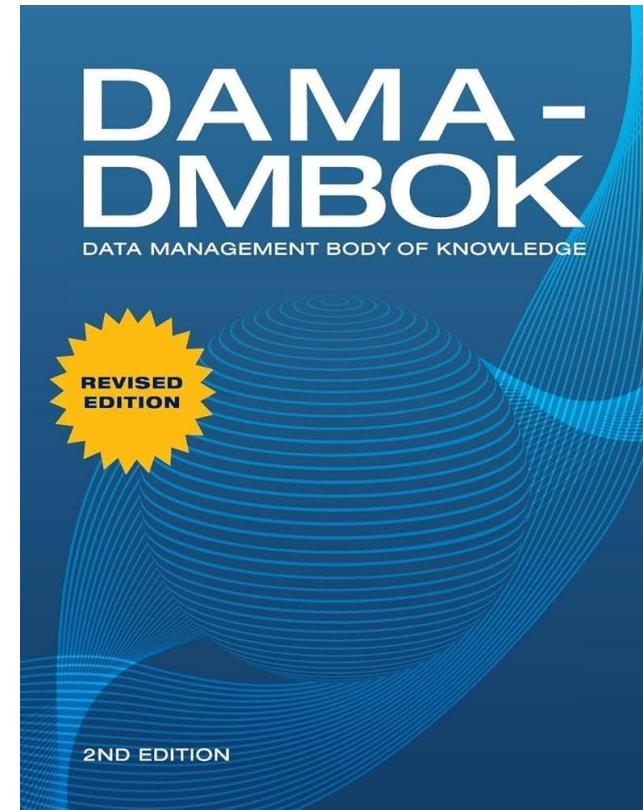
Métodos de evaluación: Encuestas, auditorías de datos, validaciones automáticas.

Herramientas de calidad de datos: Talend Data Quality, Informatica Data Quality, varias librerías de python: missingno, ydata_profiling, pandas, seaborn.

2.4 Modelos de Evaluación de Calidad de Datos

Modelo de Gestión de Datos DAMA

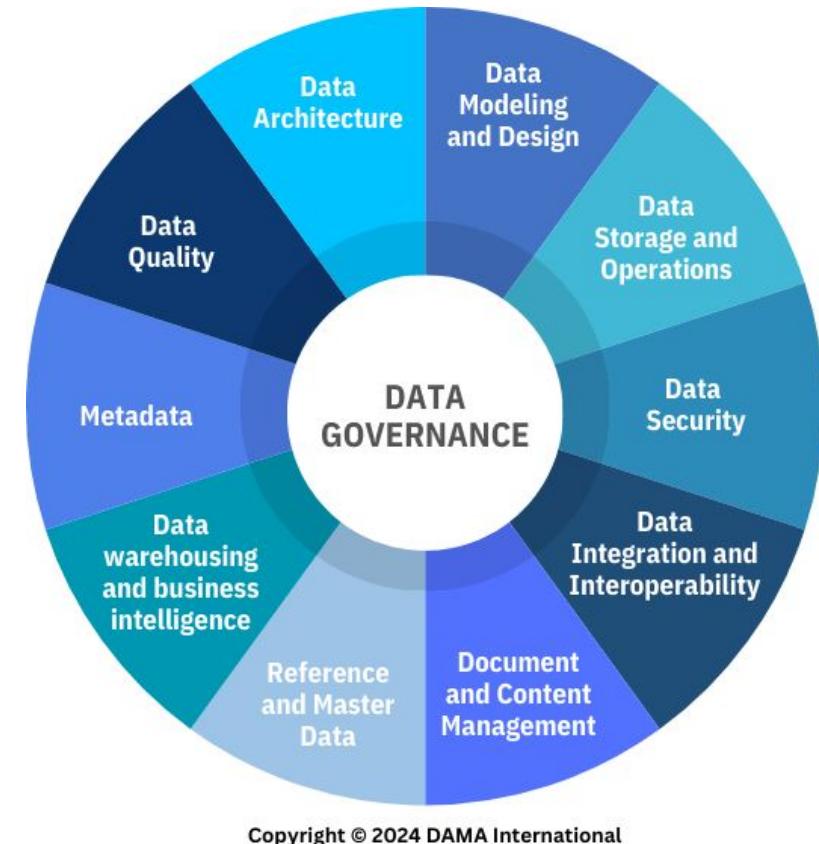
Un estándar de la gestión de datos empresariales que incluye estrategias para calidad de datos.



Modelo de Gestión de Datos DAMA

11 áreas son las que componen la famosa "**Rueda de DAMA**" (DAMA Wheel). Es el mapa completo para cualquier organización que quiera pasar de "tener datos" a "gestionar activos de información".

Lo más importante es que el **Gobierno de Datos** está en el centro, porque es el eje que conecta y da dirección a todas las demás.



Las 11 Áreas de Conocimiento de DAMA-DMBOK2

- 1. Gobierno de Datos (Data Governance):** El corazón del modelo. Se encarga de la estrategia, el control y la autoridad sobre la gestión de los datos.
- 2. Arquitectura de Datos (Data Architecture):** Define el diseño maestro para gestionar los activos de datos y alinearlos con la estrategia de la empresa.
- 3. Modelado y Diseño de Datos (Data Modeling & Design):** El proceso de descubrir, analizar y representar los requisitos de datos en modelos precisos.
- 4. Almacenamiento y Operaciones de Datos (Data Storage & Operations):** La gestión del despliegue y soporte de los datos almacenados (DBA, mantenimiento de bases de datos).

Las 11 Áreas de Conocimiento de DAMA-DMBOK2

5. Seguridad de Datos (Data Security): Asegurar la privacidad, confidencialidad y el acceso adecuado a los datos (aquí es donde entra el GDPR que mencionamos antes).

6. Integración e Interoperabilidad de Datos (Data Integration & Interoperability): Los procesos para mover y consolidar datos entre sistemas y aplicaciones.

7. Gestión de Documentos y Contenido (Document & Content Management): Gestión de datos no estructurados (PDFs, imágenes, correos) y su ciclo de vida.

8. Datos Maestros y de Referencia (Reference & Master Data): Gestión de los datos compartidos (como "Clientes" o "Productos") para reducir la redundancia y mejorar la consistencia.

Las 11 Áreas de Conocimiento de DAMA-DMBOK2

- 9. Data Warehousing y Business Intelligence (DW/BI):** La gestión del acceso a los datos para informes, análisis y toma de decisiones.
- 10. Gestión de Metadatos (Metadata Management):** Gestionar la "información sobre la información" para que los datos sean fáciles de encontrar y entender.
- 11. Gestión de la Calidad de Datos (Data Quality Management):** Asegura que los datos sean aptos para su uso.

2.4 Modelo de Evaluación de Calidad de Datos

Para evaluar la calidad de datos en un entorno organizacional, se siguen estos pasos:

- 1. Definición de criterios de calidad:** Identificación de las dimensiones más relevantes para el contexto.
- 2. Recolección de datos:** Uso de herramientas de análisis para obtener información sobre la calidad.
- 3. Análisis de resultados:** Identificación de problemas y sus causas.
- 4. Plan de mejora:** Estrategias para mejorar la calidad, como limpieza de datos, integración de fuentes o estandarización.
- 5. Monitoreo continuo:** Implementación de controles y procesos automáticos para garantizar la mejora continua.

Ejemplo de Uso del Modelo DAMA-DMBOK en Evaluación y Mejora de Calidad de Datos

Contexto del Problema

Una institución financiera detecta problemas con la calidad de datos en su sistema de gestión de clientes. Se han identificado registros con información inconsistente en nombres, direcciones y datos de cuentas, lo que genera errores en la comunicación con clientes y en la asignación de créditos.

1 Medición de Calidad de Datos

Se utilizan métricas específicas para evaluar la calidad de los datos en la base de clientes.

Dimensión de Calidad	Métrica	Resultado	Interpretación
Precisión	% de datos incorrectos en nombres o direcciones	12%	12% de los registros tienen errores ortográficos o de formato
Consistencia	% de cuentas con datos incoherentes en distintos sistemas	18%	Datos no coinciden entre la base de clientes y el sistema de facturación
Completitud	% de registros con campos vacíos	9%	9% de los clientes no tienen número de teléfono registrado
Oportunidad	Tiempo promedio para actualizar datos incorrectos	48 horas	Se tarda hasta 2 días en corregir información tras detectar un error

Evaluación y Diagnóstico

La empresa analiza los resultados de la medición y detecta los siguientes problemas:

- **Nombres y direcciones incorrectas** → Impactan la comunicación con clientes y procesos de verificación de identidad.
- **Datos inconsistentes entre sistemas** → Generan errores en la facturación y aprobaciones de crédito.
- **Falta de datos clave** → Dificulta la comunicación con clientes.
- **Tiempos de corrección lento** → Afectan la eficiencia del servicio al cliente.

Aplicación del Modelo DAMA-DMBOK

DAMA-DMBOK 2 define 11 áreas de conocimiento para la gestión de datos, para abordar la calidad de los datos utilizaremos cuatro de estas áreas:

1. Gestión de la Calidad de Datos (Data Quality Management)
2. Gestión de Datos Maestros (Master Data Management - MDM)
3. Gobierno de Datos (Data Governance)
4. Integración e Interoperabilidad de Datos

1. Gestión de la Calidad de Datos (Data Quality Management)

Este es el proceso central. DAMA lo define como el ciclo de planificar, controlar y mejorar la calidad de los datos.

- **Perfilado de Datos (Data Profiling):** Fue lo que se hizo para detectar ese **12% de errores en nombres** y el **9% de campos vacíos**. Consiste en inspeccionar los datos para entender sus fallas.
- **Limpieza y Mejora:** Aplicamos reglas de validación en los formularios para evitar que entre "basura" al sistema.

Gestión de Datos Maestros (Master Data Management - MDM)

Este proceso es el que soluciona el **18% de inconsistencia** entre la base de clientes y el sistema de facturación.

- **Identificación del "Golden Record":** DAMA busca crear una versión única y confiable de un cliente. Si el sistema de facturación y el CRM (Customer Relationship Management) dicen cosas distintas, el MDM decide cuál es la "verdad".
- **Resolución de Entidades:** Es el proceso técnico para entender que "Juan Pérez" en el sistema A es el mismo "J. Pérez" en el sistema B.

3. Gobierno de Datos (Data Governance)

Este no es un proceso técnico, sino de **autoridad y rendición de cuentas**. En el caso de la institución bancaria se utiliza para atacar el retraso de **48 horas** en las correcciones.

- **Data Stewardship:** Se asignan responsables (Custodios de Datos). Sin un Steward, nadie se siente responsable de bajar esas 48 horas.
- **Establecimiento de SLAs (Acuerdos de Nivel de Servicio):** El Gobierno de Datos define que un error crítico *debe* corregirse en menos de X horas, convirtiendo la "buena voluntad" en una norma institucional.

4. Integración e Interoperabilidad de Datos

Este proceso se encarga del **flujo de los datos** entre sistemas.

- **Sincronización:** Para resolver la inconsistencia, DAMA sugiere pasar de procesos manuales o por lotes (que causan desfases) a integraciones en tiempo real o semi-real. Esto asegura que si cambias una dirección en un sistema, se refleje instantáneamente en el resto de la institución financiera.

Otros marcos de trabajo para la evaluación de la Calidad de los Datos

Existen otros marcos de trabajo para evaluar la calidad de los datos, entre ellos encontramos:

- ❑ **Total Data Quality Management (TDQM):** A framework that manages data quality from collection to analysis. It was developed by Richard Y. Wang at MIT.
- ❑ **Data Quality Assessment Framework (DQAF):** A framework that defines standards, processes, and tools to ensure data quality. It also establishes guidelines for data governance. Utilizado en contextos gubernamentales para evaluar la calidad de datos estadísticos.
- ❑ **Data Quality Maturity Model (DQMM):** A framework that provides a roadmap for organizations to improve their data quality management practices.

Otros marcos de trabajo para la evaluación de la Calidad de los Datos

- ❑ **Data Quality Scorecard (DQS):** A framework that uses statistical approaches to identify and eliminate data issues. It also provides a structured approach to evaluating and monitoring data quality.
- ❑ **Six Sigma:** A quality management methodology that uses statistical tools and techniques to identify and eliminate sources of data errors.
- ❑ **Root Cause Analysis:** A framework that identifies the underlying causes of a data-related problem.
- ❑ **Modelo de Wang y Strong:** Define dimensiones clave como precisión, coherencia y completitud.

Recomendaciones para implementar una verificación de Calidad de datos

Verificación de Calidad de Datos

Para verificar la dimensión de Precisión

- **Verificación manual:** Realiza una comparación de los datos con fuentes confiables o datos originales. Por ejemplo, si estás trabajando con datos de ventas, compáralos con los registros financieros oficiales.
- **Pruebas de consistencia:** Asegúrate de que no haya contradicciones en los datos. Por ejemplo, un mismo cliente no debe tener dos direcciones de envío contradictorias.
- **Algoritmos de validación:** Usa herramientas automáticas para detectar valores atípicos o errores numéricos.

Verificación de Calidad de Datos

Para verificar la dimensión de Completitud

- **Revisión de valores faltantes:** Verifica que no haya campos vacíos en los registros que son clave para tu análisis. Existe una amplia diversidad de herramientas para detectar registros con valores nulos o vacíos (SQL, pandas(python), Informatica, Apache Hop, etc.)
- **Validación de registros:** Compara tus datos con un conjunto de datos de referencia para asegurarte de que los datos esperados están presentes.
- **Imputación de datos faltantes:** Si encuentras datos faltantes, puedes rellenarlos mediante técnicas de imputación, dependiendo del tipo de datos.

Verificación de Calidad de Datos

Para verificar la dimensión de Consistencia

- **Reglas de validación:** Establece reglas que aseguren la coherencia. Por ejemplo, si una columna contiene códigos de país, todos los registros deben ajustarse a un conjunto de códigos válidos.
- **Análisis cruzado:** Verifica que los datos sean consistentes cuando se cruzan entre diferentes bases de datos o sistemas.
- **Detección de duplicados:** Usa herramientas para identificar registros duplicados o inconsistentes, como buscar nombres duplicados, fechas incorrectas o IDs repetidos.

Verificación de Calidad de Datos

Para verificar la dimensión de Oportunidad (en el aspecto de Actualización)

- **Revisión periódica:** Establece procedimientos para revisar y actualizar los datos de manera regular, especialmente si estás utilizando datos en tiempo real o dinámicos (como precios de productos o inventarios).
- **Establecimiento de ciclos de actualización:** Si los datos se actualizan automáticamente, verifica la frecuencia con la que esto sucede y asegúrate de que los cambios se reflejan correctamente.
- **Auditorías de datos:** Realiza auditorías periódicas para confirmar que los datos se han actualizado correctamente en el sistema.

Otras dimensiones

Para verificar la dimensión de Fiabilidad

- **Verificación de fuentes:** Asegúrate de que las fuentes de los datos sean confiables y estén bien establecidas. Por ejemplo, si obtienes datos de una API, verifica que esa API esté documentada y sea mantenida activamente.
- **Evaluación de origen de datos:** Identifica el origen de los datos para confirmar que provienen de fuentes legítimas y verificables.
- **Auditoría de la recopilación de datos:** Realiza auditorías para asegurar que los procesos de captura de datos sean correctos y que no haya errores introducidos durante la recopilación.

Otras dimensiones

Para verificar la dimensión de Relevancia

- **Evaluación del contexto:** Pregúntate si los datos que estás utilizando son realmente relevantes para el propósito que deseas. Asegúrate de que los datos estén alineados con los objetivos de tu análisis.
- **Eliminación de datos innecesarios:** Si los datos no son útiles o no aportan valor, considera eliminarlos del conjunto para evitar que generen ruido en los análisis.
- **Conformidad con estándares del sector:** Si trabajas en un área específica (finanzas, salud, marketing, etc.), asegúrate de que los datos que manejas cumplan con los estándares de calidad del sector.

Otras dimensiones

Para verificar la dimensión de Accesibilidad (Podría ser otro aspecto de la dimensión de oportunidad)

- **Revisión de permisos y acceso:** Verifica que los datos estén accesibles para las personas que los necesiten, sin barreras innecesarias. Asegúrate de que las políticas de privacidad o de seguridad no impidan el acceso a los datos.
- **Facilidad de acceso:** Evalúa si los datos están disponibles en formatos que sean fáciles de usar (como CSV, JSON, bases de datos SQL) y que puedan ser procesados sin problemas por las herramientas que uses.
- **Pruebas de accesibilidad:** Realiza pruebas para asegurarte de que los datos puedan ser consultados y utilizados sin demoras o dificultades técnicas.

Algoritmos y herramientas en Calidad de datos

Algoritmos y herramientas en calidad de datos

Detección de Duplicados

Algoritmos de comparación exacta: Estos algoritmos verifican la existencia de registros duplicados mediante una comparación exacta de todos los campos. Usualmente se utilizan en bases de datos para identificar registros duplicados.

- **Método:** Comparación de todos los valores de los registros (campos de texto, numéricos, etc.) para ver si son exactamente iguales.
- **Herramientas comunes:** SQL `DISTINCT`, Pandas (Python).

Verificación de Calidad de Datos

Algoritmos de comparación aproximada (Fuzzy Matching): Cuando los registros no son exactamente iguales, pero contienen errores tipográficos o variaciones, se puede usar un enfoque de coincidencia difusa (fuzzy matching).

- **Método:** Algoritmos como **Levenshtein Distance** (distancia de edición) o **Jaro-Winkler** miden la similitud entre cadenas de texto.
- **Herramientas comunes:** FuzzyWuzzy (Python), RecordLinkage (Python).

Verificación de Calidad de Datos

Detección de Valores Atípicos

- **Algoritmos estadísticos:** Los valores atípicos (outliers) son aquellos que se desvían significativamente del comportamiento esperado de los datos. Algunos algoritmos que ayudan en esta tarea incluyen:
 - **Z-Score:** Identifica outliers basados en la desviación estándar de los datos. Si el valor de una observación tiene un Z-score superior a un umbral determinado (por ejemplo, ± 3), se considera un outlier.
 - **IQR (Interquartile Range):** Usa el rango intercuartílico para identificar valores atípicos. Los datos fuera del rango de $Q1 - 1.5 \times IQR$ y $Q3 + 1.5 \times IQR$ son considerados outliers.
 - **Método de Boxplot:** Utiliza un gráfico de caja (boxplot) para identificar los valores atípicos visualmente.

Verificación de Calidad de Datos

Detección de Valores Atípicos

- **Modelos de aprendizaje automático:**
 - **Isolation Forest:** Un algoritmo de aprendizaje no supervisado que es eficiente para detectar valores atípicos en grandes conjuntos de datos.
 - **Local Outlier Factor (LOF):** Detecta outliers al comparar la densidad local de los puntos con sus vecinos.

Referencias

- Redman, T. C. (1996). Data Quality: The Field Guide. Digital Press.
- Wang, R. Y., & Strong, D. M. (1996). Beyond Accuracy: What Data Quality Means to Data Consumers. *Journal of Management Information Systems*, 12(4), 5-33.
- Pipino, L. L., Lee, Y. W., & Wang, R. Y. (2002). Data quality assessment. *Communications of the ACM*, 45(4), 211-218.
- Batini, C., & Scannapieco, M. (2016). Data Quality: Concepts, Methodologies and Techniques. Springer.
- Kimball, R., & Caserta, J. (2004). The Data Warehouse ETL Toolkit: Practical Techniques for Extracting, Cleaning, Conforming, and Delivering Data. Wiley.