Unidad 4
Tema 4.4 Fusión de datos

Fusión de datos

- **Introducción a fusión de datos**
- **Estrategias para manejo de conflictos y poder fusionar datos**
- **Obtención de registro de oro**

INFORMATICA®

Recordando…

Al integrar diversas fuentes tenemos:

1. Inconsistencias *"intensionales"* o esquemáticas que se resuelven por correspondencia de esquemas y mapeo de esquemas

2. Inconsistencias extensionales que se resuelven por detección de duplicados/record linkage y fusión de datos

En fusión de datos, a partir de los datos disponibles se debe decidir por la mejor opción considerando una de estas acciones:

- **Tomar una opción y descartar las demás**
- **Complementar una opción con la otra**
- **Transformar ambas opciones en una tercera**

INFORMATICA®

Introducción

- **El término fusión de datos es muy utilizado durante el manejo de datos provenientes de sensores.**
- **Los métodos más utilizados para realizar la fusión de datos de este tipo son:**
  - Métodos bayesianos
  - Inferencia Dempster-Shafer (generalización de teoría bayesiana)
  - Razonamiento abductivo
  - Métodos semánticos
- **Mas información en artículo A Review of Data Fusion Techniques: https://www.hindawi.com/journals/tswj/2013/704504/**

INFORMATICA

Introducción

- **La fusión de datos es el último paso durante el proceso de integración de datos.**

- **El término fusión de datos que se abordará será:**

Proceso por el cual dos o más representaciones de la misma entidad se combinan en una sola representación en la cual las inconsistencias se han resuelto.

INFORMATICA®

Introducción

- **Existen dos tipos de conflictos:**

1.-Contradicciones: si dos o más fuentes de datos proporcionan dos o más valores diferentes para el mismo atributo.

- Causas: errores tipográficos introducidos al ingresar los datos, errores ortográficos simples o desactualización

2. Incertidumbres: conflicto entre un valor no nulo y uno o más valores nulos que se utilizan para describir la misma propiedad de un objeto

- Causas: falta de información.

INFORMATICA

Introducción

- **En el caso de las incertidumbres, recordemos que existen tres posibles interpretaciones de valor nulo:**

  (i) Valor desconocido: el valor existe, pero quien sea que ingresó los datos no lo sabía.

  (ii) Valor inaplicable: la propiedad correspondiente no es aplicable para el objeto representado por esta tupla.

  (iii) Valor retenido: los datos existen pero no se permite ver

Lo anterior complica la resolución de conflictos

INFORMATICA

Introducción

- **El objetivo de las estrategias para el manejo de conflictos de datos es el poder llegar a una respuesta fija, exacta y única y no con varias respuestas y probabilidades adicionales que dificultan poder fusionar los datos.**

- **Las estrategias pueden describir una decisión sobre qué valor tomar, cómo combinar valores o cómo inventar un nuevo valor, y de esa manera describir la representación única y consistente creada durante la fusión de datos.**

INFORMATICA®

Estrategias para fusión/resolución de conflictos entre datos

- **Clasificación de estrategias**

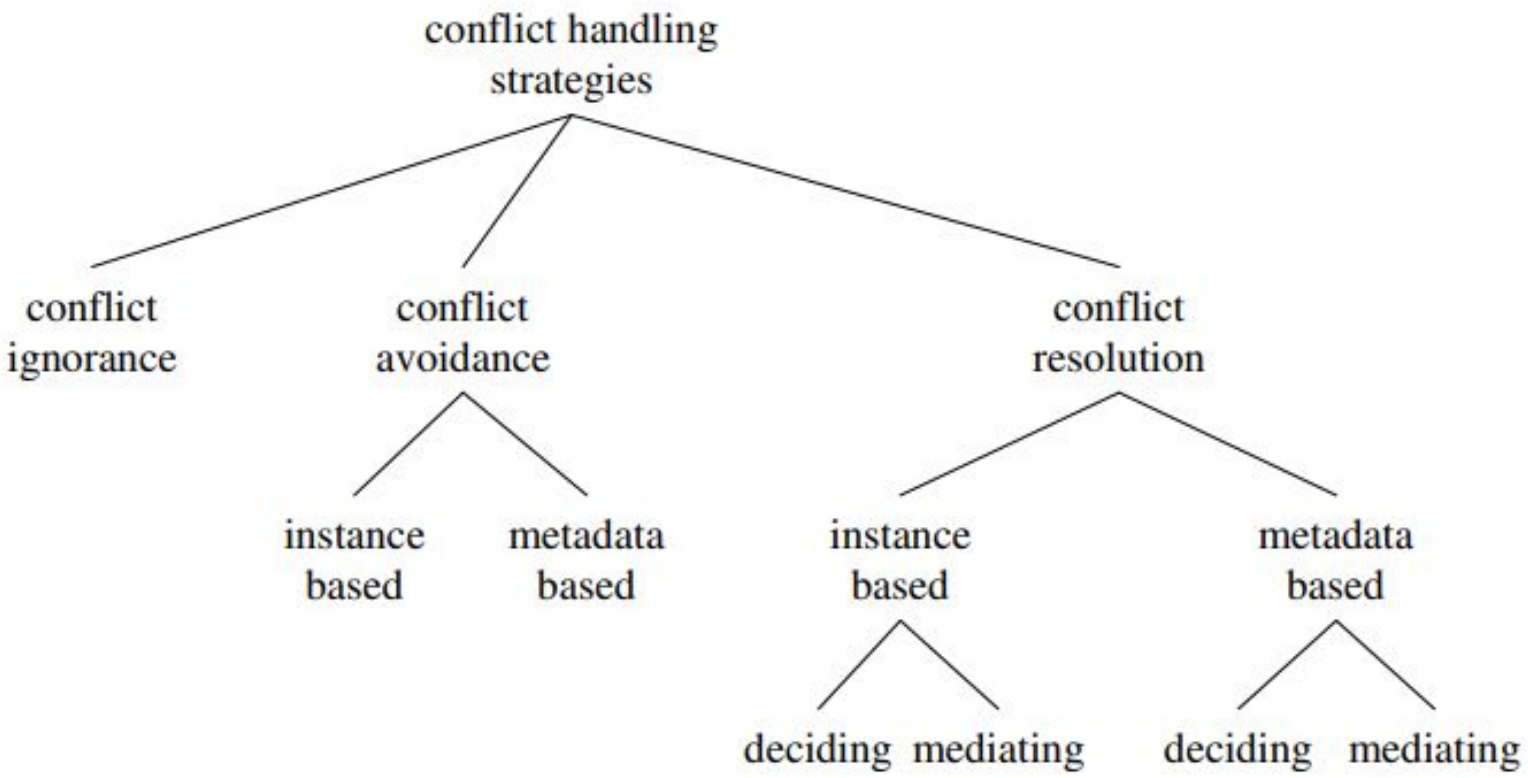

INFORMATICA

Ignorar el conflicto

- **No tomar una decisión en absoluto.**
  - Se utiliza cuando esta información no es necesaria ni utilizada.
- **Tipos:**
  - ***Dejarlo pasar/Pass it on:*** Envía los valores en conflicto al usuario o a la aplicación para que se decida como resolver el conflicto.
  - ***Considerar todas las posibilidades:*** Envía diferentes soluciones o combinaciones posibles de los datos

INFORMATICA®

Evitar el conflicto

- **Se toma una decisión rápida** para el manejo de todas las inconsistencias y decide por un valor a utilizar. Por lo general se toma la decisión antes de saber el conflicto.
  - **Ventajas:** Computacionalmente barato
  - **Desventajas:** Se pierde precisión ya que no se toma en cuenta toda la información para resolver el conflicto.
  - **Se divide en:**
    - Decisión basada en metadatos para tomar una decisión
    - Basada en instancia, dado que no se basa en metadatos sino en los valores en conflicto.

INFORMATICA®

Evitar el conflicto

- **Existen dos estrategias basadas en instancia:**
  - ***Tomar la información:*** se toma la información existente y la información no presente se deja de lado.
    - Esta estrategia deja de lado los valores nulos para solucionar las incertidumbres.
    - Puede filtrar nulos innecesarios (por ejemplo con los operadores minimum union, outerjoint, así como la función Coalesce)
    - Esta estrategia es razonable si solo hay incertidumbres, pero no hay conflictos en los datos.
  - ***No gossiping:*** para el caso de inconsistencias en el resultado de consultas (queries), solo las respuestas consistentes (evitando los datos inconsistentes por restricción en la consulta) son incluidas en el resultado.

INFORMATICA®

Evitar el conflicto

- **Ejemplo de estrategia basada en metadatos.**
  - ***Confía en tus amigos:*** Preferir datos de una fuente sobre los datos de otras fuentes.

Intuitivamente, la preferencia de una fuente de datos sobre otra puede decidirse con base en que la fuente sea proporcionada por un usuario de confianza, o por costo de la fuente, o por tamaño o por criterios de calidad.

INFORMATICA®

Resolución de conflicto

- Se tienen **en cuenta todos los datos y metadatos antes de decidir** cómo resolver un conflicto. Esto es computacionalmente más costoso que otras estrategias, pero proporciona medios para resolver el conflicto de la manera más óptima.
- **Esta estrategia se divide a su vez en:**
  - ***Estrategia de decisión:*** Escoge el valor de entre los presentes que puede basarse solo en instancia y/o en metadatos
  - ***Estrategia de mediación:*** Puede escoger un valor que no se encuentra entre los existentes.

INFORMATICA®

Resolución de conflicto

- Las estrategias de decisión permiten y usan la proveniencia/linaje de datos, particularmente de donde provienen.
- Las estrategias de decisión basadas en instancia se dividen en:
  - ***Llora con los lobos***
  - ***Tira el dado***

Un ejemplo de estrategia de mediación es:

- ***Encontrarse en el punto medio***

Un ejemplo de estrategia de decisión basada en metadatos es:

- ***Mantenerse actualizado/al día***

INFORMATICA®

Resolución de conflictos

- **Dos estrategias de decisión basadas en instancia:**
- ***Llora con los lobos*.** Se considera que los valores correctos prevalecen sobre los incorrectos, cuando existe suficiente evidencia. Sigue el principio de seguir la decisión de la mayoría al elegir el valor más común de entre aquellos conflictivos.

- ***Tirar los dados.*** Elige valores en conflicto al azar. A falta de información para decidir, un valor aleatorio puede ser una buena opción. Esto requiere que uno sea consciente de un conflicto(por ejemplo conociendo de antemano columnas donde los conflictos sean más probables), pero tiene la ventaja de ser computacionalmente económico.

INFORMATICA®

Resolución de conflictos

Una estrategia de decisión basada en metadatos es:

- *Mantenerse al día.* Utiliza el valor más reciente, requiere información adicional como marca de tiempo para saber que tan actual es el valor. Esta información puede estar presente como un atributo separado o proporcionado por otros medios, como linaje de datos.

INFORMATICA®

Function	Description
COUNT	Counts the number of distinct NON-NULL values, i.e., the number of conflicting values. Only *indicates* conflicts, the actual data values are lost.
MIN / MAX	Returns the minimal/maximal input value with its obvious meaning for numerical data. Lexicographical (or other) order is needed for non numerical data.
SUM / AVG / MEDIAN	Computes sum, average, and median of all present NON-NULL data values.
VARIANCE / STDDEV	Returns variance and standard deviation of data values.
RANDOM	Randomly chooses one data value among all NON-NULL data values.
CHOOSE	Returns the value supplied by a specific source.
COALESCE	Returns the first NON-NULL value appearing.
FIRST / LAST	Returns the first/last value, even if it is a NULL value.
VOTE	Returns the value that appears most often among the present values. Ties can be broken by a variety of strategies, e.g., choosing randomly.
GROUP	Returns a set of all conflicting values. Leaves conflict resolution to the user.
SHORTEST / LONGEST	Chooses the value of minimum/maximum length according to a length measure.
(ANNOTATED) CONCAT	Returns the concatenated values. May include annotations, such as the names of the data sources.
HIGHEST QUALITY	Returns the value of highest information quality. Requires an underlying quality model.
MOST RECENT	Returns the most recent value. Recency is evaluated with the help of another attribute or other metadata about tuples/values.
MOST ACTIVE	Returns the most often accessed or used value. Access statistics of the DBMS can be used in evaluating this function.
CHOOSE DEPENDING	Chooses the value v in column A that belongs to a specific given value c in another column B. B and c are given.
CHOOSE CORRESPONDING	Chooses the value v in column A that belongs to the value v' already chosen for another column B. B is given.
MOST COMPLETE	Returns the value of the source that contains the fewest NULL values in the attribute in question.
MOST DISTINGUISHING	Returns the value that is the most distinguishing among all present values in that column.
MOST GENERAL CONCEPT / MOST SPECIFIC CONCEPT	Using a taxonomy or ontology this function returns the more general value (lowest common ancestor) or the more specific value (if the values are on a common path in the taxonomy).

Algunas funciones que implementan estrategias de manejo de conflictos tomado de:

J. Bleiholder and F. Naumann. Declarative data fusion - syntax, semantics, and implementation. In Proc. of ADBIS, pages 58–73, Tallinn, Estonia, 2005.

J. Bleiholder and F. Naumann. Conflict handling strategies in an integrated information system.Technical Report Informatik-Berichte, Nr. 197,Humboldt-Universit¨at zu Berlin, 2006.

INFORMATICA

Fusión de datos basado en proveniencia y/o calidad de datos

Como se puede observar, existen diferentes formas de llevar a cabo una estrategia, por ejemplo:

- La estrategia “Confía en tus amigos” también se puede lograr usando la función “*Elegir Dependiendo”* tomando una columna en alguna de las fuentes disponibles y el nombre de la fuente deseada como segundo parámetro, o a través del valor más alto de calidad y entonces tener un puntaje de calidad como parámetro que favorece la fuente deseada.
- A continuación se muestra ejemplo de funciones y las estrategias a las que obedecen.

Strategy	Possible functions to realize the strategy
PASS IT ON	GROUP, CONCAT
CONSIDER ALL POSSIBILITIES	[6, 19]
TAKE THE INFORMATION	COALESCE, LONGEST
NO GOSSIPING	[1, 10]
TRUST YOUR FRIENDS	CHOOSE, CHOOSE DEPENDING, HIGHEST QUALITY, FIRST, MOST COMPLETE, CHOOSE CORRESPONDING
CRY WITH THE WOLVES	VOTE
ROLL THE DICE	RANDOM
MEET IN THE MIDDLE	AVERAGE, MEDIAN, MOST GENERAL
KEEP UP TO DATE	MOST RECENT, FIRST

Tomado de: J. Bleiholder and F. Naumann. Conflict handling strategies in an integrated information system.Technical Report Informatik-Berichte, Nr. 197,Humboldt-Universit¨at zu Berlin, 2006.

INFORMATICA

Fusión de datos/ conflictos

- Contradicciones
- Incertidumbres

Estrategia Manejo de Conflictos

Ignorar

- No tomar decisión ; no se usa el atributo (no relevante o dependiente)
- Dejar pasar; se presentan los valores conflictivos
- Considerar posibilidades; se presentan combinaciones de valores conf.

Evitar

- Se decide rápidamente un valor antes de conocer el conflicto por proveniencia

Con base en metadatos
- Confía en amigos: Se usa el mejor costo, tamaño o calidad

Con base en instancia (valores)
- Tomar información: Se usa el valor existente (cuando hay incertidumbre)
- No gossiping: Se usa el resultado consistente (cuando hay conflicto entre consultas)

Resolver

por Decisión

Con base metadatos y/o
- Mantenerse actualizado: Usa el valor más reciente

Con base instancia
- Llora con lobos: Elije valor más común
- Tira los dados: Elije valor al azar

por mediación
- Escoge un valor diferente a los conflictos (un 3º)
- tomar el punto medio

Golden record en Master Data Management

How Informatica Can Help

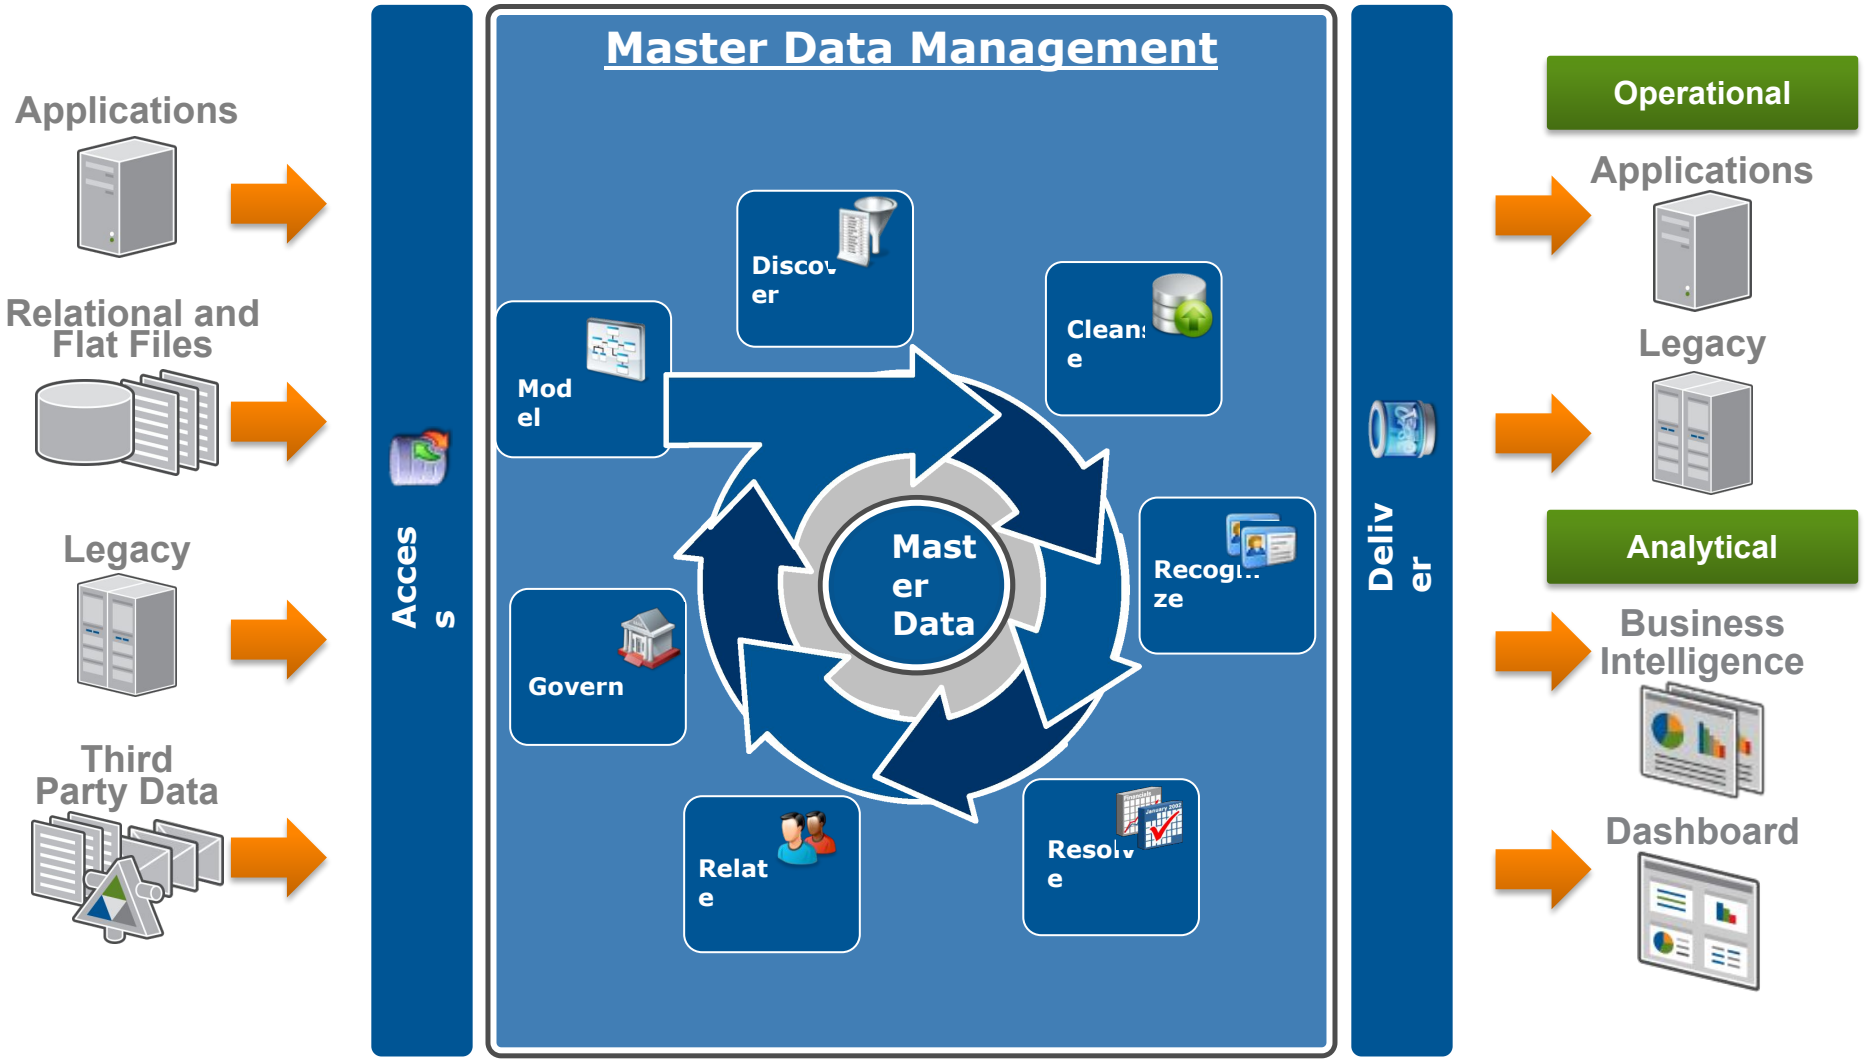

INFORMATICA

Flexible Business Model-driven MDM

Flexible, Client-driven MDM
(Informatica)

An adaptive approach that relies on configuration based on unique requirements

- Flexible approach to data model
- Automatically generated services
- Configurable user interface, workflow

Adapting to Your Requirements

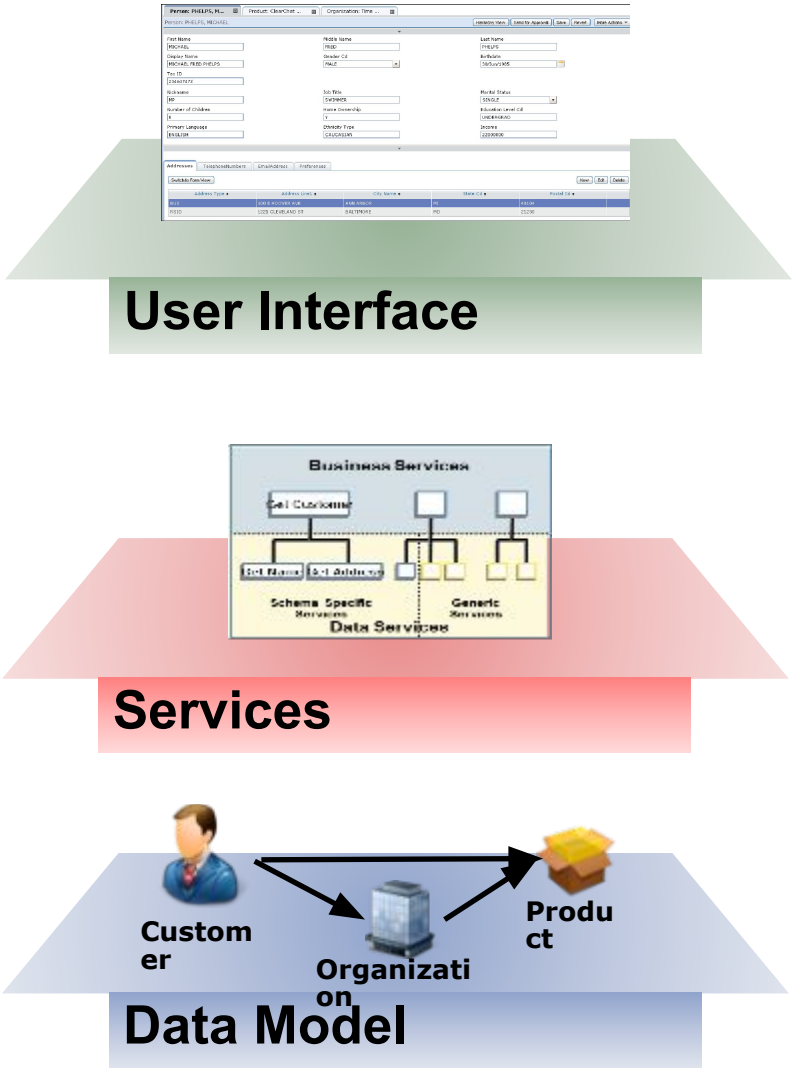

informatica

Flexible Business Model-driven MDM

Flexible, Client-driven MDM
(Informatica)

An adaptive approach that relies on configuration based on unique requirements

- Flexible approach to data model
- Automatically generated services
- Configurable user interface, workflow

Adapting to Your Requirements

- Changes regenerate services, UI
- Requires lower level technical expertise

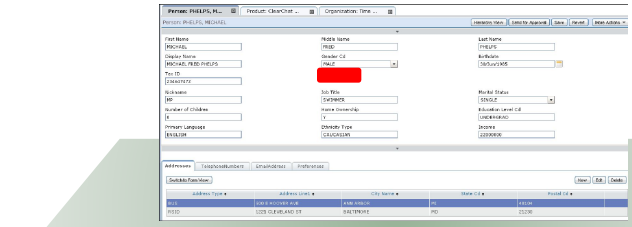

User Interface

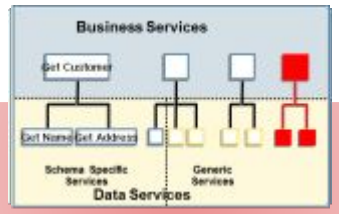

Services

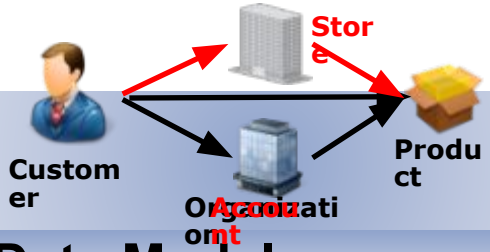

Data Model

informatica

Key Foundational Elements for MDM

Data Profiling

Key requirements for success:

- Discover and document all anomalies in the data
- Catalog issues in completeness, conformity, consistency, accuracy, duplicates, dependencies

Products:

- Informatica Data Analyst

Key Foundational Elements for MDM

Data Quality

Products:
- Informatica Data Quality
- AddressDoctor

Key requirements for success:
- Data cleansing
- Data enrichment
- Address standardization
- Data monitoring and reporting
- SOA based access to DQ rules
- Conditional Formatting
- Validation rules
- Data Conversion, Noise removal, Transformation
- Open cleanse architecture

Informatica MDM Hub

Core Capabilities: Recognize

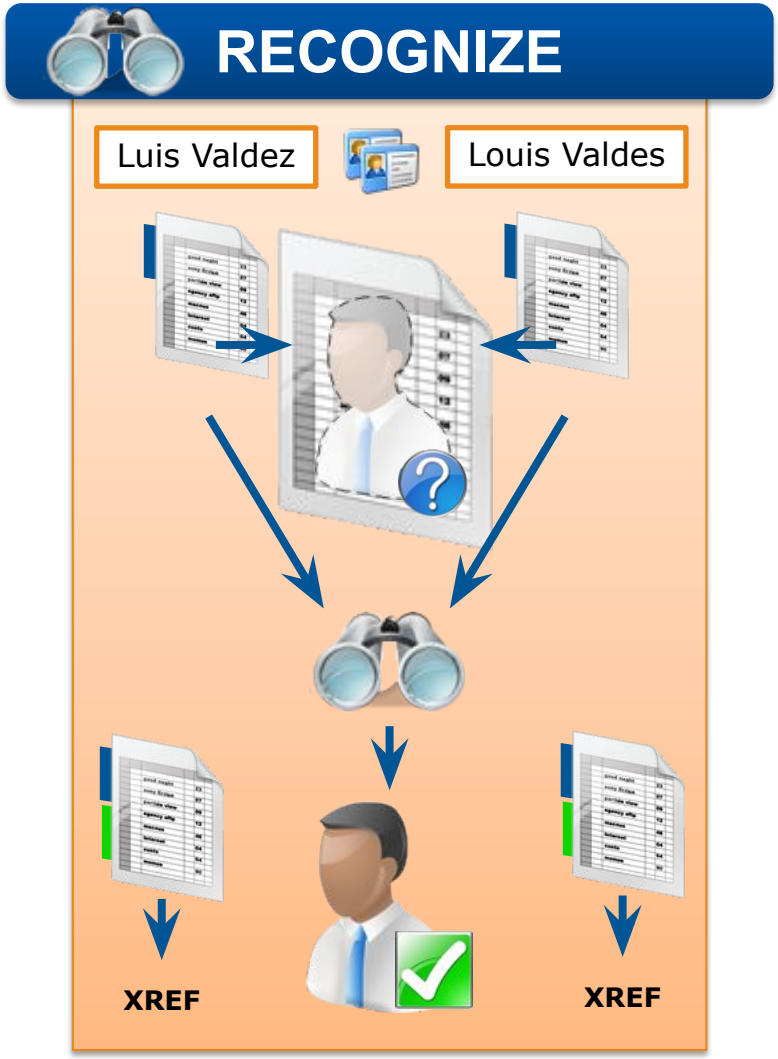

RECOGNIZE the entity accurately across multiple systems

- **Identify candidates for matches across multiple systems based on configurable rules**
- **Determine match, non-match based on user defined thresholds**
- **Queue questionable matches for manual review**

informatica

Informatica MDM Hub

Core Capabilities: Resolve

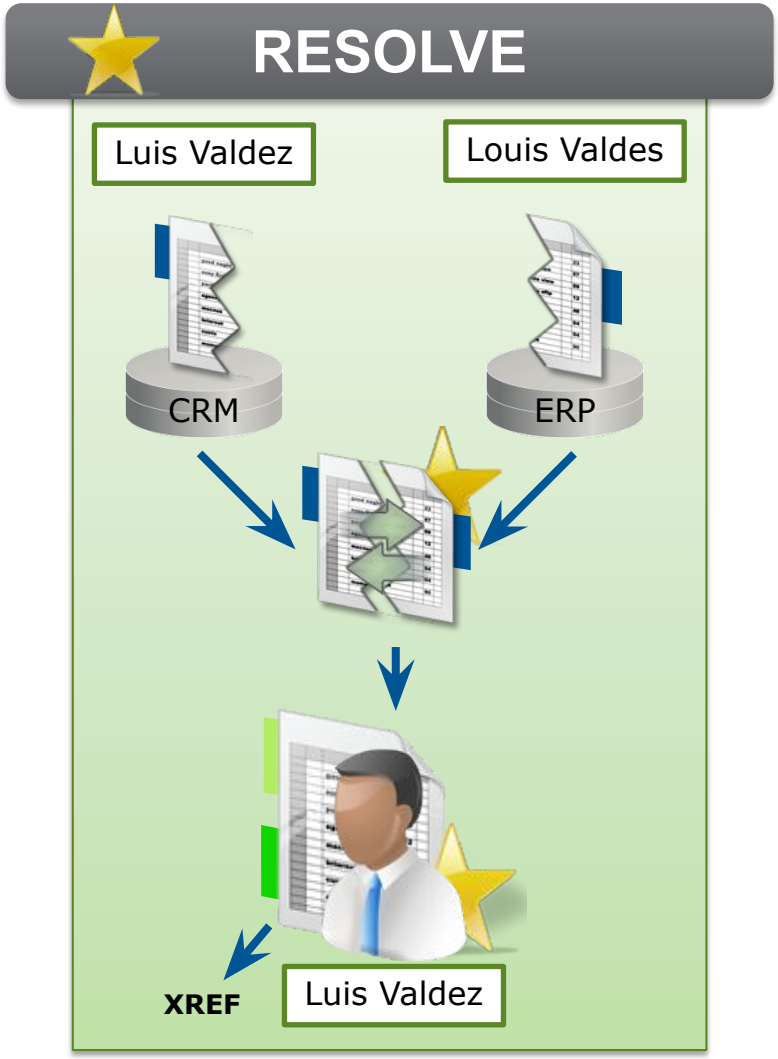

<u>RESOLVE</u> data conflicts among the systems into a trusted source of truth

- **As necessary, matched records are merged to a "golden record"**
- **The most reliable attributes are selected to survive, at the cell level, based on configurable rules**
- **All history and lineage of changes is kept**

informatica

Informatica MDM Hub

Assembling the Best Version of Truth

Golden Record

Party Name	Public	Domicile	Industry	As of Date	Total Assets	Liquid Assets	Equity	Credit Rating
IXIS Corporate & Investment Bank	Y	France	6021	1/31/2006	$207,059	$190,157	$3,342	AAA-
UnionBanCal	Y	USA	6021	3/27/2006	$207,059	$190,157	$3,342	AA-
General Electric Company	Y	USA	3511	4/15/2006	$481,741	$383,522	$40,666	AAA

CRM

FULL NAME	SWIFT #	ADDR1	CITY	ADDR4	ADDR5	COUNTRY
Union Bank of California	308-03-8500	Elm and Carlton Streets	Minneapolis	MN	50423	USA
General Electric Company	005-10-4640	123 Main Street	New Haven	CT	14263	USA
IXIS Corporate & Investment Bank	917-13-8500	57, rue du Foubourg	Paris		75003	France

Finance

Account #	Bank Name	As of Date	Total Assets	Liquid Assets	Equity	Country	Rating
30803850041	Union Bank.	8/26/1950	$207,059	$190,157	$3,342	US	Baa
00510464002	General Electric	6/15/1978	$481,741	$383,522	$40,666	US	AAA
91713850028	IXIS Corporate & Investment Bank	4/30/1953	$673,342	$559,934	$109,354	FR	Aaa

Legacy

SFA_ID #	Company Name	Ticker Symbol	SIC Code	Address	City	State	Zip
21399	IXIS CIB		6021	57 rue du Foubourg	Paris		75003
50382	Bank of Mitsubishi	WFC	6021	6th and Marquette	Minneapolis	MN	55405
62098	GE Financial	GE	3511	123 Main St	New Haven	CT	

informatica

Informatica MDM Hub

Core Capabilities: Relate

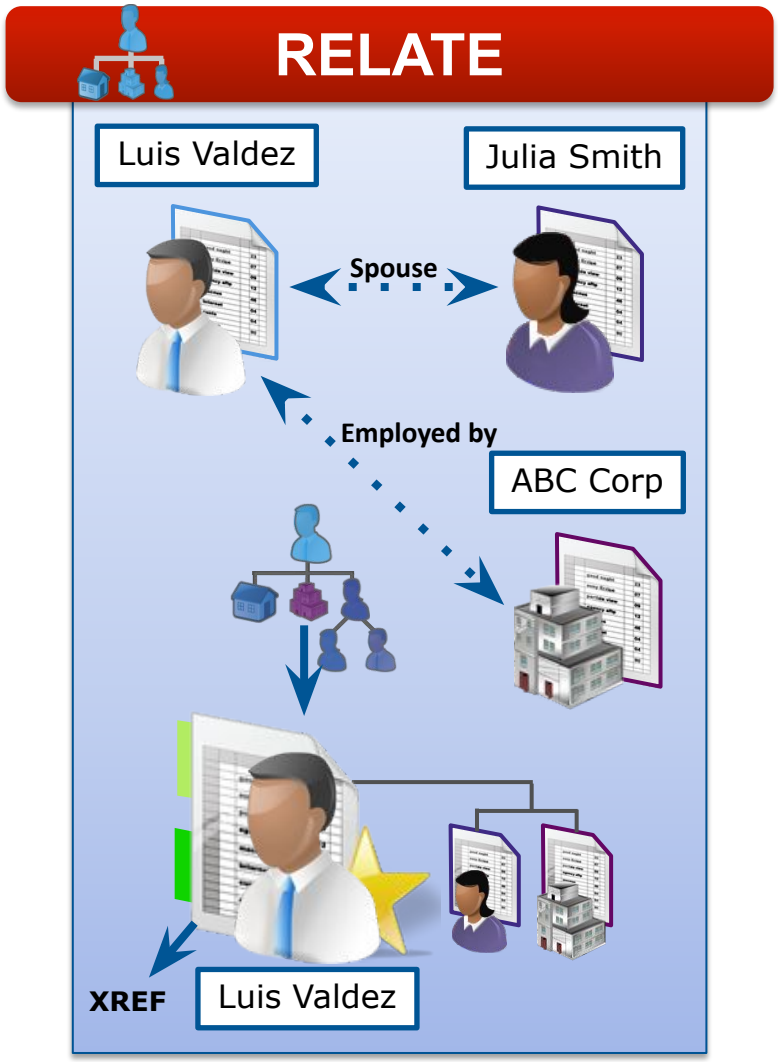

<u>RELATE</u> people, locations, products, and organizations from different sources

- **Bring together relationships from different applications and systems**
- **Create and manage a rich set of multiple hierarchies for different purposes**
- **Maintain history and lineage of relationship changes**

informatica

Informatica Data Quality

Crear una cuenta de prueba en INFORMATICA Data Quality:

https://www.informatica.com/trials/cloud-data-quality.html