Calidad y Preprocesamiento de Datos

MCIC VÍCTOR MANUEL CORZA VARGAS

MC FERNANDO AVITÚA VARELA

6. Reducción de dimensionalidad

Objetivo de la Unidad

Al finalizar esta unidad, el estudiante será capaz de:

- Comprender la importancia de reducir la dimensionalidad de los datos.
- Identificar y eliminar atributos redundantes utilizando técnicas estadísticas.
- Seleccionar y conservar los atributos más relevantes para un problema específico utilizando diversos métodos.

6.1 Eliminar Atributos Redundantes

Los atributos redundantes son aquellos que no aportan información nueva o útil al conjunto de datos porque su información ya está contenida (total o parcialmente) en otros atributos. Eliminar la redundancia ayuda a simplificar el modelo, reducir la multicolinealidad (en modelos lineales) y disminuir los costos computacionales sin una pérdida significativa de información. La redundancia se evalúa típicamente analizando las relaciones *entre los propios atributos predictores*.

Técnicas: Test Chi-cuadrado ($\chi 2$) para Independencia:

- **Propósito:** Se utiliza principalmente para evaluar la asociación o independencia entre dos **atributos categóricos**.
- **Aplicación en Redundancia:** Si dos atributos categóricos están fuertemente asociados (es decir, el test indica que *no* son independientes con un nivel de significancia alto), uno podría considerarse redundante respecto al otro. Por ejemplo, si tenemos ciudad y codigo_postal_parcial y están altamente correlacionados, podríamos quedarnos solo con uno.
- **Funcionamiento (Conceptual):** Compara las frecuencias observadas en una tabla de contingencia (que cruza los dos atributos) con las frecuencias que se esperarían si los atributos fueran independientes. Un valor alto de $\chi 2$ (y un p-valor bajo) sugiere una fuerte dependencia.
- **Consideraciones:** Requiere que los datos sean categóricos (o discretizados). La interpretación del estadístico $\chi 2$ depende de los grados de libertad.

Test Chi-cuadrado ($\chi 2$) para Independencia:

- **Contexto:** Imaginemos que trabajamos para una empresa de telecomunicaciones y tenemos datos de clientes. Queremos saber si existe una relación (asociación) entre el **Tipo de Plan Contratado** (un atributo categórico) y si el cliente utiliza principalmente el servicio para **Navegación Web o Streaming** (otro atributo categórico).
- Si encontramos una asociación muy fuerte, podría indicar que estos dos atributos nos dan información similar sobre el perfil del cliente. En algunos escenarios de modelado, podríamos considerar si uno de ellos es parcialmente redundante.

Test Chi-cuadrado ($\chi 2$) para Independencia:

Paso 1: Definir las Variables y la Pregunta

- **Variable 1 (Categórica):** Tipo_Plan (Valores: Básico, Intermedio, Premium)
- **Variable 2 (Categórica):** Uso_Principal (Valores: Navegación, Streaming)
- **Pregunta:** ¿El tipo de plan que contrata un cliente está asociado con si su uso principal es la navegación web o el streaming de video?

Paso 2: Formular las Hipótesis

- **Hipótesis Nula (H0):** No existe asociación entre el Tipo_Plan y el Uso_Principal. Son independientes. (Saber el plan no ayuda a predecir el uso principal, y viceversa).
- **Hipótesis Alternativa (Ha):** Existe una asociación entre el Tipo_Plan y el Uso_Principal. Son dependientes. (El tipo de plan está relacionado con el uso principal).

Test Chi-cuadrado (χ2) para Independencia:

Paso 3: Recolectar Datos y Crear la Tabla de Contingencia (Frecuencias Observadas)

Supongamos que tomamos una muestra de 200 clientes y obtenemos los siguientes datos:

Tipo de Plan / Uso Principal	Navegación	Streaming	Total por Plan
Básico	60	10	**70**
Intermedio	30	30	**60**
Premium	10	60	**70**
Total por Uso	**100**	**100**	**200 (Total)**

Esta tabla muestra las **frecuencias observadas (O)**. Por ejemplo, 60 clientes con Plan Básico usan principalmente el servicio para Navegación.

Test Chi-cuadrado (χ2) para Independencia:

Paso 4: Calcular las Frecuencias Esperadas (E)

Las frecuencias esperadas son las que esperaríamos ver en cada celda *si la hipótesis nula (H0) fuera cierta* (es decir, si las variables fueran independientes). Se calculan para cada celda como:

$$E_{ij} = \frac{(\text{Total Fila } i) \times (\text{Total Columna } j)}{\text{Total General}}$$

Calculemos algunas:

- Esperado (Básico, Navegación) = (70 * 100) / 200 = 35
- Esperado (Básico, Streaming) = (70 * 100) / 200 = 35
- Esperado (Intermedio, Navegación) = (60 * 100) / 200 = 30
- Esperado (Intermedio, Streaming) = (60 * 100) / 200 = 30
- Esperado (Premium, Navegación) = (70 * 100) / 200 = 35
- Esperado (Premium, Streaming) = (70 * 100) / 200 = 35

Test Chi-cuadrado (χ2) para Independencia:

Tabla de Frecuencias Esperadas (E):

Tipo de Plan / Uso Principal	Navegación	Streaming	Total por Plan
Básico	35	35	**70**
Intermedio	30	30	**60**
Premium	35	35	**70**
Total por Uso	**100**	**100**	**200 (Total)**

Test Chi-cuadrado (χ2) para Independencia:

Paso 5: Calcular el Estadístico Chi-Cuadrado (χ2)

El estadístico χ2 mide la discrepancia total entre las frecuencias observadas (O) y las esperadas (E). Se calcula sumando para todas las celdas:

$$\chi^2 = \sum \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

Calculemos término a término:

- Celda (Básico, Navegación): $(60-35)^2/35=25^2/35=625/35\approx17.86$
- Celda (Básico, Streaming): $(10-35)^2/35=(-25)^2/35=625/35\approx17.86$
- Celda (Intermedio, Navegación): $(30-30)^2/30=0^2/30=0$
- Celda (Intermedio, Streaming): $(30-30)^2/30=0^2/30=0$
- Celda (Premium, Navegación): $(10-35)^2/35=(-25)^2/35=625/35\approx17.86$
- Celda (Premium, Streaming): $(60-35)^2/35=25^2/35=625/35\approx17.86$

Sumamos todos los términos: χ2=17.86+17.86+0+0+17.86+17.86=**71.44**

Test Chi-cuadrado ($\chi 2$) para Independencia:

Paso 6: Determinar los Grados de Libertad (df)

Los grados de libertad indican cuántas celdas pueden variar libremente una vez que los totales marginales (totales de filas y columnas) están fijos.

$df = (\text{número de filas} - 1) \times (\text{número de columnas} - 1)$

$df = (3 - 1) \times (2 - 1) = 2 \times 1 = 2$

Test Chi-cuadrado ($\chi 2$) para Independencia:

Paso 7: Encontrar el **valor crítico** asociado a un **nivel de significancia (α)**

1. Eliges un nivel de significancia α (ej. 0.05) *antes* de mirar la tabla.
2. Calculas tu estadístico $\chi 2$ y los grados de libertad (df).
3. Buscas en la tabla el valor crítico para tus df y tu α elegido.
4. **Comparas:** Si tu $\chi 2$ calculado > $\chi 2$ crítico de la tabla, entonces rechazas la hipótesis nula (H0) al nivel de significancia α. (Concluyes que tu p-valor es *menor que* α.)

Limitación: Esta tabla **no te dice el p-valor exacto** de tu estadístico calculado. Solo te permite saber si es mayor o menor que los α específicos listados en la tabla.

Test Chi-cuadrado ($\chi 2$) para Independencia:

Usando la Tabla Tradicional para *Aproximar* el P-valor (Menos Preciso):

Aunque no da el valor exacto, puedes usar la tabla de valores críticos para tener una *idea* del rango en que se encuentra tu p-valor:

1. Ve a la fila correspondiente a tus grados de libertad (df=2 en el ejemplo).
2. Busca en esa fila dónde encajaría tu estadístico $\chi 2$ calculado (71.44).
3. Observa los valores críticos en esa fila. Por ejemplo, para df=2, podrías encontrar:
   - χ^2critico(α=0.05)=5.991
   - χ^2critico(α=0.01)=9.210
   - χ^2critico(α=0.001)=13.815
4. Tu valor calculado (71.44) es *mucho mayor* que el valor crítico incluso para α=0.001.
5. **Conclusión Aproximada:** Esto te dice que tu p-valor es *mucho menor* que 0.001 ($p<0.001$). No te da el valor exacto (como 2.77×10^{-16}), pero confirma que el resultado es altamente significativo.

Test Chi-cuadrado (χ2) para Independencia:

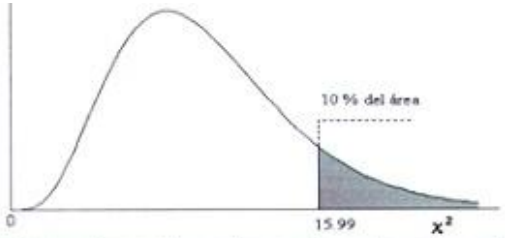

Ejemplo:
Para $\phi = 10$ grados de libertad

$P[\chi^2 > 15.99] = 0.10$

Grados de libertad

alfa

ϕ \ α	0.995	0.99	0.975	0.95	0.9	0.75	0.5	0.25	0.1	0.05	0.025	0.01	0.005	ϕ \ α
1	3.93E-05	1.57E-04	9.82E-04	3.93E-03	1.58E-02	0.102	0.455	1.323	2.71	3.84	5.02	6.63	7.88	1
2	1.00E-02	2.01E-02	5.06E-02	0.103	0.211	0.575	1.386	2.77	4.61	5.99	7.38	9.21	10.60	2
3	7.17E-02	0.115	0.216	0.352	0.584	1.213	2.37	4.11	6.25	7.81	9.35	11.34	12.84	3
4	0.207	0.297	0.484	0.711	1.064	1.923	3.36	5.39	7.78	9.49	11.14	13.28	14.86	4
5	0.412	0.554	0.831	1.145	1.610	2.67	4.35	6.63	9.24	11.07	12.83	15.09	16.75	5
6	0.676	0.872	1.237	1.635	2.20	3.45	5.35	7.84	10.64	12.59	14.45	16.81	18.55	6
7	0.989	1.239	1.690	2.17	2.83	4.25	6.35	9.04	12.02	14.07	16.01	18.48	20.3	7
8	1.344	1.647	2.18	2.73	3.49	5.07	7.34	10.22	13.36	15.51	17.53	20.1	22.0	8
9	1.735	2.09	2.70	3.33	4.17	5.90	8.34	11.39	14.68	16.92	19.02	21.7	23.6	9
10	2.16	2.56	3.25	3.94	4.87	6.74	9.34	12.55	15.99	18.31	20.5	23.2	25.2	10
11	2.60	3.05	3.82	4.57	5.58	7.58	10.34	13.70	17.28	19.68	21.9	24.7	26.8	11
12	3.07	3.57	4.40	5.23	6.30	8.44	11.34	14.85	18.55	21.0	23.3	26.2	28.3	12
13	3.57	4.11	5.01	5.89	7.04	9.30	12.34	15.98	19.81	22.4	24.7	27.7	29.8	13
14	4.07	4.66	5.63	6.57	7.79	10.17	13.34	17.12	21.1	23.7	26.1	29.1	31.3	14
15	4.60	5.23	6.26	7.26	8.55	11.04	14.34	18.25	22.3	25.0	27.5	30.6	32.8	15
16	5.14	5.81	6.91	7.96	9.31	11.91	15.34	19.37	23.5	26.3	28.8	32.0	34.3	16
17	5.70	6.41	7.56	8.67	10.09	12.79	16.34	20.5	24.8	27.6	30.2	33.4	35.7	17
18	6.26	7.01	8.23	9.39	10.86	13.68	17.34	21.6	26.0	28.9	31.5	34.8	37.2	18
19	6.84	7.63	8.91	10.12	11.65	14.56	18.34	22.7	27.2	30.1	32.9	36.2	38.6	19
20	7.43	8.26	9.59	10.85	12.44	15.45	19.34	23.8	28.4	31.4	34.2	37.6	40.0	20
21	8.03	8.90	10.28	11.59	13.24	16.34	20.3	24.9	29.6	32.7	35.5	38.9	41.4	21
22	8.64	9.54	10.98	12.34	14.04	17.24	21.3	26.0	30.8	33.9	36.8	40.3	42.8	22
23	9.26	10.20	11.69	13.09	14.85	18.14	22.3	27.1	32.0	35.2	38.1	41.6	44.2	23
24	9.89	10.86	12.40	13.85	15.66	19.04	23.3	28.2	33.2	36.4	39.4	43.0	45.6	24
25	10.52	11.52	13.12	14.61	16.47	19.94	24.3	29.3	34.4	37.7	40.6	44.3	46.9	25
26	11.16	12.20	13.84	15.38	17.29	20.8	25.3	30.4	35.6	38.9	41.9	45.6	48.3	26
27	11.81	12.88	14.57	16.15	18.11	21.7	26.3	31.5	36.7	40.1	43.2	47.0	49.6	27
28	12.46	13.56	15.31	16.93	18.94	22.7	27.3	32.6	37.9	41.3	44.5	48.3	51.0	28
29	13.12	14.26	16.05	17.71	19.77	23.6	28.3	33.7	39.1	42.6	45.7	49.6	52.3	29
30	13.79	14.95	16.79	18.49	20.6	24.5	29.3	34.8	40.3	43.8	47.0	50.9	53.7	30
40	20.7	22.2	24.4	26.5	29.1	33.7	39.3	45.6	51.8	55.8	59.3	63.7	66.8	40
50	28.0	29.7	32.4	34.8	37.7	42.9	49.3	56.3	63.2	67.5	71.4	76.2	79.5	50
60	35.5	37.5	40.5	43.2	46.5	52.3	59.3	67.0	74.4	79.1	83.3	88.4	92.0	60
70	43.3	45.4	48.8	51.7	55.3	61.7	69.3	77.6	85.5	90.5	95.0	100.4	104.2	70
80	51.2	53.5	57.2	60.4	64.3	71.1	79.3	88.1	96.6	101.9	106.6	112.3	116.3	80
90	59.2	61.8	65.6	69.1	73.3	80.6	89.3	98.6	107.6	113.1	118.1	124.1	128.3	90
100	67.3	70.1	74.2	77.9	82.4	90.1	99.3	109.1	118.5	124.3	129.6	135.8	140.2	100
Z_α	-2.58	-2.33	-1.96	-1.64	-1.28	-0.674	0.000	0.674	1.282	1.645	1.96	2.33	2.58	Z_α

Otras técnicas para reducir dimensionalidad: Correlación

- **Propósito:** Mide la fuerza y dirección de la relación *lineal* (Pearson) o *monótona* (Spearman) entre dos **atributos numéricos**.
- **Aplicación en Redundancia:** Si dos atributos numéricos tienen un coeficiente de correlación (Pearson 'r' o Spearman 'rho') muy alto en valor absoluto (cercano a 1 o -1, por ejemplo, $|r|>0.85$ o $|r|>0.9$), significa que se mueven juntos de forma predecible. Uno de ellos puede ser eliminado por ser redundante. Por ejemplo, altura_cm y altura_pulgadas tendrían una correlación perfecta ($r=1$) y son completamente redundantes. Peso e IMC (Índice de Masa Corporal) probablemente tengan una correlación alta.

Correlación

Funcionamiento (Conceptual):

- **Correlación de Pearson (r):** Mide la relación lineal. Va de -1 (correlación negativa perfecta) a +1 (correlación positiva perfecta), con 0 indicando ausencia de relación *lineal*. Sensible a outliers.
- **Correlación de Spearman (rho):** Mide la relación monótona (si una variable tiende a aumentar cuando la otra aumenta, sin necesidad de que sea lineal). Se basa en los rangos de los datos, por lo que es menos sensible a outliers. También va de -1 a +1.

Correlación

Consideraciones: La correlación estándar (Pearson) solo captura relaciones lineales. Una correlación baja no implica necesariamente independencia (podría haber una relación no lineal fuerte).

Es importante visualizar las relaciones (gráficos de dispersión) además de calcular los coeficientes. Se debe definir un umbral para decidir cuándo la correlación es "suficientemente alta" para considerar un atributo redundante.

Revisar: **Libreta pearson**

6.2 Conservar Atributos Relevantes (Selección de Características)

Mientras que el tema anterior se enfoca en eliminar atributos basados en sus relaciones *entre sí*, este apartado se centra en seleccionar y conservar aquellos atributos que son más *informativos* o *predictivos* con respecto a una **variable objetivo** (en aprendizaje supervisado) o que mejor explican la estructura de los datos (en aprendizaje no supervisado). Este proceso se conoce formalmente como **Selección de Características (Feature Selection)**. El objetivo es encontrar un subconjunto óptimo de atributos que maximice el rendimiento del modelo o la comprensión del fenómeno.

6.3 Clasificación General de Métodos de Selección

Métodos de Filtro (Filter Methods): Evalúan la relevancia de los atributos basándose en sus características estadísticas intrínsecas (ej. correlación con la variable objetivo, ganancia de información), independientemente del modelo de aprendizaje que se usará después. Son rápidos y computacionalmente eficientes. (Correlación, Información mutua (Entropía-Ganancia), Chi-cuadrado con el target suelen ser filtros).

Revisar: **Libreta pearson_heatmap**

Información mutua (Information Gain):

Propósito: Técnica de *filtro*, originaria de la teoría de la información. Mide cuánta información sobre la **variable objetivo (categórica)** se gana al conocer el valor de un atributo.

Aplicación en Selección: Se calcula la ganancia de información para cada atributo con respecto a la variable objetivo. Aquellos atributos con mayor ganancia de información se consideran más relevantes para predecir la clase.

Información mutua (Information Gain):

La **información mutua** mide **cuánta información comparte una variable con otra**. Es decir, **cuánto reduce la incertidumbre (Entropía)** sobre una variable al conocer la otra.

- Si XXX y YYY son **totalmente independientes**, su información mutua es **0**.
- Si conocer XXX determina completamente YYY, la información mutua es **alta**.

Fórmula de información mutua (discreta):

$$I(X;Y) = \sum_{x \in X} \sum_{y \in Y} P(x,y) \cdot \log_2 \left(\frac{P(x,y)}{P(x) \cdot P(y)} \right)$$

- P(x,y): probabilidad conjunta de xxx e yyy
- P(x),P(y): probabilidades marginales
- Se mide en **bits**

Información mutua (Information Gain):

Ejemplo práctico:

ID	Clima	Actividad
1	Soleado	Playa
2	Soleado	Playa
3	Nublado	Cine
4	Lluvia	Cine
5	Lluvia	Cine
6	Nublado	Cine
7	Soleado	Playa
8	Lluvia	Cine
9	Nublado	Cine
10	Soleado	Playa

Información mutua (Information Gain):

Paso 1: Probabilidades marginales

- P(Soleado)=4/10
- P(Nublado)=3/10
- P(Lluvia)=3/10
- P(Playa)=4/10
- P(Cine)=6/10

Paso 2: Probabilidades conjuntas

- P(Soleado,Playa)=4/10
- P(Nublado,Cine)=3/10
- P(Lluvia,Cine)=3/10

(otras combinaciones tienen 0 registros)

Información mutua (Information Gain):

Paso 3: Aplicar la fórmula

$$I(X;Y) = \sum P(x,y) \cdot \log_2 \left(\frac{P(x,y)}{P(x)P(y)} \right)$$

Para Soleado–Playa:

$$I = \frac{4}{10} \cdot \log_2 \left(\frac{4/10}{(4/10)(4/10)} \right) = 0.4 \cdot \log_2 \left(\frac{1}{0.4} \right) = 0.4 \cdot \log_2(2.5) \approx 0.4 \cdot 1.32 = 0.528$$

Realizas lo mismo con los otros pares (Nublado–Cine y Lluvia–Cine).

El resultado final es la **suma de estos valores**, que en este caso es **la información mutua total entre Clima y Actividad**.

Revisar: Libreta informacion_mutua_manual

Revisar: Libreta informacion_mutua

Clasificación General de Métodos de Selección

Métodos de Envoltura (Wrapper Methods): Utilizan un algoritmo de aprendizaje específico para evaluar la utilidad de diferentes subconjuntos de atributos. Miden directamente el rendimiento del modelo con cada subconjunto. Suelen ser más precisos pero computacionalmente mucho más costosos. (Rank Search, Forward Selection, Backward elimination, suelen ser wrappers).

Clasificación General de Métodos de Selección

Rank Search (Búsqueda por Ranking):

- **Propósito:** No es un algoritmo específico, sino una *estrategia* de tipo *filtro* o a veces *wrapper* simple. Consiste en ordenar (rankear) los atributos según algún criterio de relevancia y seleccionar los 'k' mejores.
- **Aplicación en Selección:** Se utiliza una métrica (ej. Ganancia de Información, Correlación con el target, $\chi 2$ con el target, importancia de características de un modelo simple) para asignar una puntuación a cada atributo. Luego, se ordenan los atributos por esta puntuación y se elige un número predefinido (k) de los mejores, o aquellos que superen un cierto umbral de puntuación.

Clasificación General de Métodos de Selección

Rank Search (Búsqueda por Ranking):

- **Funcionamiento (Conceptual):** Calcular métrica -> Rankear -> Seleccionar Top-k.
- **Consideraciones:** Simple y rápido. No considera las interacciones entre atributos (un atributo puede ser poco útil por sí solo pero muy útil en combinación con otro).

Revisar: Libreta Chi2

Clasificación General de Métodos de Selección

Greedy Stepwise Search (Búsqueda Voraz Paso a Paso):

- **Propósito:** Estrategia de tipo *wrapper*. Construye un subconjunto de atributos de forma iterativa, tomando decisiones localmente óptimas en cada paso.
- **Aplicación en Selección:** Utiliza un modelo de aprendizaje específico para evaluar subconjuntos de características.

Clasificación General de Métodos de Selección

Greedy Stepwise Search (Búsqueda Voraz Paso a Paso):

- **Forward Selection (Selección Hacia Adelante):** Empieza sin atributos. En cada paso, añade el atributo (que no esté ya seleccionado) que produce la mayor mejora en el rendimiento del modelo (ej. mayor precisión, menor error). Se detiene cuando añadir más atributos no mejora significativamente el rendimiento.
- **Backward Elimination (Eliminación Hacia Atrás):** Empieza con todos los atributos. En cada paso, elimina el atributo cuya remoción cause la menor degradación (o la mayor mejora) en el rendimiento del modelo. Se detiene cuando eliminar más atributos degrada significativamente el rendimiento.
- **Bidirectional (Stepwise):** Combina pasos hacia adelante y hacia atrás.

Clasificación General de Métodos de Selección

Greedy Stepwise Search (Búsqueda Voraz Paso a Paso):

- **Consideraciones:** Es "voraz" (greedy) porque nunca reconsidera una decisión anterior (un atributo añadido nunca se remueve en Forward Selection, y uno removido nunca se vuelve a añadir en Backward Elimination). Puede quedarse atascado en óptimos locales. Computacionalmente más caro que los filtros porque entrena/evalúa el modelo múltiples veces.

Revisar:

Libreta forward-selection

Libreta backward-selection

Clasificación General de Métodos de Selección

Métodos Embebidos (Embedded Methods): La selección de características se realiza como parte integral del proceso de entrenamiento del modelo. Ejemplos incluyen LASSO (regresión con regularización L1) o la importancia de características derivada de Random Forests.

Revisar:

Libreta LASSO

Libreta Random Forest

Referencias

Han, J., Pei, J., & Tong, H. (2022). Data mining: concepts and techniques. Morgan kaufmann.

Ponniah, P. (2004). Data warehousing fundamentals: a comprehensive guide for IT professionals. John Wiley & Sons.

Scikit-learn documentation. Preprocessing data https://scikit-learn.org/stable/modules/preprocessing.html